UNIVERSIDADE FEDERAL DE ALAGOAS
INSTITUTO DE COMPUTAÇÃO

Processamento de Linguagem Natural - graduação
Professor: Thales Vieira

2a lista de exercícios **19 de agosto de 2026**

Instruções:
A lista deve ser respondida por grupos de até 2 pessoas.
Resoluções idênticas de grupos distintos serão desconsideradas.
O código e demais dados devem ser anexados a cada questão.
Data limite para entrega: 18/09/2026.

Nas questões abaixo, você não está sendo avaliado pela implementação, mas pela sua capacidade de análise dos métodos aplicados em sua base (escolha dos hiperparâmetros, discussão sobre os resultados dentre os diferentes métodos, etc.). Respostas somente com implementação não serão avaliadas.

1. Escolha 5 documentos da sua base pré-processada, e determine seu documento mais parecido, dentre todos os documentos da base (não pode ser ele mesmo), usando:

a) Representação vetorial CountVectorizer com similaridade do cosseno;
b) Representação vetorial TF-IDF com similaridade do cosseno.

Justifique, para cada par de documentos mais parecidos, porque cada representação considerou o par semelhante.

2. Elabore um problema de classificação de textos coerente com sua base, com pelo menos 3 classes.

a) Determine qual será o rótulo dos documentos (separando os documentos em classes bem definidas).
b) Extraia as representações vetoriais com CountVectorizer e TF-IDF, considerando os textos já préprocessados como na primeira lista.
c) Treine um classificador baseado em cada uma das duas representações vetoriais, e escolhendo três dos seguintes classificadores: Regressão Logística, Naive Bayes, SVM (com kernel linear), k-NN ou Random

Forest. Use validação cruzada com 70% das amostras selecionadas para treino e 30% para teste. Exiba as matrizes de confusão, métricas de acurácia, precisão, recall e F1 score micro e macro.

d) Compare os resultados.

3. Você deverá aplicar dois métodos de modelagem de tópicos sobre uma base textual, utilizando a representação TF-IDF dos textos:

- um método clássico, à sua escolha entre LDA, NMF ou SVD truncado;
- e o método BERTopic.

a) Defina um número de tópicos apropriado para sua base e justifique a escolha com base em interpretação qualitativa ou métricas de coerência.
b) identifique as 5 palavras mais relevantes de cada tópico;
c) identifique o tópico mais relevante de 5 documentos quaisquer (você pode representar os tópicos por suas 5 palavras mais relevantes).
d) qual método apresentou melhores resultados, na sua opinião? Justifique com resultados/dados.