UNIVERSIDADE FEDERAL DE ALAGOAS
INSTITUTO DE COMPUTAÇÃO

Processamento de Linguagem Natural - graduação
Professor: Thales Vieira

3a lista de exercícios **15 de outubro de 2026**

Instruções:

A lista deve ser respondida por grupos de até 2 pessoas.
Resoluções idênticas de grupos distintos serão desconsideradas.
O código e demais dados devem ser anexados a cada questão.
Data limite para entrega: 02/11/2026.

Usando sua base de textos após os pré-processamento realizados na lista 1, realize as seguintes tarefas:

1. O coeficiente de silhueta mede o quanto um documento está próximo dos documentos do seu próprio grupo em comparação com os documentos do grupo vizinho mais próximo. Para cada documento (i), definem-se:

- (a(i)): a distância média entre (i) e os demais documentos do seu grupo;
- (b(i)): a menor distância média entre (i) e os documentos de outro grupo, considerando separadamente cada um dos outros grupos.

A silhueta do documento é calculada por:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

Seu valor varia entre (-1) e (1):

- Valores próximos de 1 indicam que o documento está bem agrupado.
- Valores próximos de 0 indicam pouca distinção entre seu grupo e o grupo vizinho mais próximo.
- Valores negativos indicam que o documento está, em média, mais próximo de outro grupo do que do seu próprio grupo.

O coeficiente de silhueta médio é a média dos valores (s(i)) de todos os documentos. Quanto maior esse valor, melhor o agrupamento segundo esse critério.

Realize agrupamento dos dados usando o algoritmo k-means, tentando encontrar um valor adequado para k. Use o coeficiente de silhueta médio como critério,

plotando um gráfico onde o eixo horizontal representa valores de k, e o eixo vertical representa o coeficiente de silheuta médio. Realize essa tarefa considerando as seguintes representações vetoriais:

a) TF-IDF
b) Representação vetorial dos documentos no espaço latente obtido com o método clássico de modelagem de tópicos escolhido na questão 5 da lista anterior.

2. Nesta questão você deve aplicar métodos de projeção multidimensional para visualizar os dados no espaço visual, usando os resultados da segunda e terceira questões.

a) aplique os método de projeção multidimensional t-SNE na representação TF-IDF e plote o gráfico da projeção resultante, colorindo os pontos de acordo com os grupos obtidos na questão 1a.
b) experimente variar o hiperparâmetro **perplexity** do t-SNE no experimento da questão 2a. O que acontece com as projeções quando estes parâmetros são calibrados para valores menores ou maiores do que seus valores padrão?
c) aplique o método de projeção multidimensional t-SNE os vetores usados na questão 1b. Encontre bons valores para o hiperparâmetro **perplexity** do t-SNE, e plote os gráfico das melhores projeções obtidas por cada método de projeção, colorindo os pontos de acordo com os grupos obtidos em 1b.

3. O objetivo dessa questão é desenvolver buscadores de palavras e documentos. Utilize tokenização e normalização compatíveis com o modelo pré-treinado escolhido. Remova stopwords e não aplique stemização. Desconsidere palavras que não possuam vetor no modelo. Aplique a mesma normalização às palavras de consulta. Use sempre a distância do cosseno nos itens abaixo.

a) escolha e aplique um modelo do tipo word2vec **pretreinado** a seus textos, compatível com o idioma dos textos (inglês ou português).
b) escolha 5 palavras de consulta distintas que não estejam em nenhum dos textos. Para cada palavra de consulta, encontre as 3 palavras **de seu conjunto de textos** mais parecidas com cada uma das palavras de consulta e exiba os documentos onde estas palavras aparecem.
c) Seja d um documento da base e w uma palavra de consulta. Implemente o seguinte algoritmo para buscar documentos:
    1. Para cada documento d, considere o conjunto $V(d)$ de palavras distintas que restaram após o pré-processamento e possuem vetor no modelo. Desconsidere documentos para os quais $V(d)$ seja vazio.
    2. Determine $L_5(d, w)$: a lista das cinco palavras de $V(d)$ com menor distância em relação a w. Se $V(d)$ contiver menos de cinco palavras,

utilize todas elas.

3. Calcule a distância média entre a consulta e as palavras selecionadas:

$$DM_5(d, w) = \frac{1}{|L_5(d, w)|} \sum_{t \in L_5(d,w)} \text{dist}(w, t).$$

4. Recupere os três documentos da base com os menores valores de $DM_5(d, w)$.

4. Resolva novamente seu problema de classificação de textos da lista anterior e compare com os resultados obtidos anteriormente, usando:

a) Uma arquitetura de rede neural que utilize camadas de Embedding e LSTM.
b) Uma arquitetura de rede neural que utilize camadas de Embedding e convolucionais 1d.

5. Usando sua base de textos e a biblioteca spaCy, realize as seguintes tarefas:

a) Extraia as etiquetas gramaticais (POS) de cada token dos seus textos.
b) Calcule e plote um gráfico com as frequências de cada tipo gramatical.
c) Escolha um tipo de entidade nomeada pretreinada em algum modelo da spaCy. Dê preferência a um tipo de entidade que tenha uma boa chance de aparecer mais de uma vez em cada documento. Realize o reconhecimento destas entidades em seus textos.
d) Gere um grafo com pesos onde os nós representam cada entidade reconhecida, e as arestas são criadas caso pares de entidades apareçam juntas num mesmo documento. O peso das arestas deve ser igual à quantidade destas ocorrências. Plote o grafo usando a biblioteca NetworkX, onde as arestas devem ser desenhadas com espessura proporcional ao peso. Obs.: Se o grafo ficar visualmente poluído, plote apenas os vértices representando entidades com maior frequência, com suas respectivas arestas.